


低时延agent

Agent形态：从协作到异步自主完成任务；交互从被动“问-答”到“主动推荐-用户选择”




Agent能够独立完成更长的任务

子趋势1：人类时间有限不可扩展
-> **agent 7*24h连续可工作**

子趋势2：人类交互频率有限
-> **agent需更自主地工作**

子趋势3：人类能力有限
-> **agent需完成更复杂任务**



前端agent

- 实现极致的全模态交互体验
- 低时延：交互强调时延
- 理解用户意图
- 交互介入：任务结果反馈

后端agent


- **Stateful**：有长期记忆，经验不断被保存，持续自迭代
- **自主完成任务**：小时级，天级，月级任务
- **事件驱动**：任务触发
- **预先reasoning**：可以对高频，常见场景/信息预先处理

Agent系统最大挑战：环境异构计算，长轨异步和编排，经验多级存储，多agent高并发低时延

新变化+挑战


环境scaling: 多个复杂环境联合探索，一个Agent将处理操控、信息查询、写代码等诸多能力，以及MCP成百上千的生态工具

挑战: 1. 环境计算成为关键一环，CPU可阻塞GPU，拉低系统效率；
2. 异构计算下CPU-GPU需协同，配比可调；
3. 工具沙箱需稳定，可扩展




轨迹scaling: 多轮决策和推理，任务长度可达天级，周级

挑战: 1. 推理长尾增加GPU空置率，工具长尾降低系统吞吐；
2. 多任务，多阶段，多模型，多工具特点要求多步异步和高效编排




经验scaling: 环境交互中积累经验，从中学习提升能力

挑战: 1. 多级存储，长时记忆存储和短时KV Cache结合，存储资源冷热分层，层次化Cache资源池等挑战；
2. 训推协同，支持边推理边训练




Agent scaling: 多agent并行部署，高频地交互和协作，需要低时延

挑战: 1. 高吞吐，大量agent同时并发；
2. 低时延，高频率的机-机交互




业界思路

异构算力协同调度




实例持久化驻留，减少冷启动开销
SkyRL: 弹性沙盒部署



多级异步混合推理


Autellix: 以项目为单元调度优化，提升吞吐4-15x

任务动态分发：依任务优先级和依赖关系，动态切分任务并高效编排减少空泡
LLM推理和工具调用：子任务内各阶段长度和次数不同编排




经验记忆池化共享

谷歌：轨迹语义压缩存储和抽取




经验数据分层存储




软硬协同

硬件: Ayar Labs推断agent高并发低时延的负载需要光I/O支持




算法: 通过高效prefix caching大幅提高QPS



Agent端到端 ‘好多省快’ 体验：准确性，鲁棒性，效率和时延


Agent体验目标~能完成任务 x 稳定可靠完成任务 x 低成本完成任务 x 低时延体验

准确性持续摸高




在挑战任务上 (ARC-AGI) 持续摸高

任务鲁棒性 (4/4 Reliability)




采用“4/4 可靠性”评估方法：只有当模型在全部四次尝试中均正确回答问题时，才被视为成功

提升任务效率




模型生成速度不断提升



每秒输出token数不断提高


Agent部署未来趋势：真实复杂环境 x 独立长任务 x 多agent部署 x 异步交互

多复杂digital环境



多个复杂环境联合探索，一个Agent将处理操控、信息查询、写代码等诸多能力，以及MCP生态工具==下一代Agent: GPT5? Gemini 3?

独立长任务




完成任务时长每7个月增加1倍，Claude4
最长任务已达7小时，将很快突破天级任务

多agent部署

tokens fast. In our data, agents typically use about 4× more tokens than chat interactions, and multi-agent systems use about 15× more tokens than chats. For economic viability, multi-agent systems

Anthropic: 单agent和多agent系统的 token消耗量分别比chat多4倍和15倍


异步交互




后台agent预先/投机等异步执行减少时延

Agent架构：80%通用（做好推理加速），20%随场景模块化组成

基于ReACT范式的agentic模型



从reasoning模型到agentic模型的特点

- ① Agent的机-机交互：高频，24h不间断**
 - 系统支持超高QPS
 - 推理和工具调用低时延，支持agent间高频交互
 - 推理系统高可靠能持续工作
- ② 人生尺度的历史轨迹+agent间历史交互数据**
 - 长时记忆存储和短期KVCache结合，存储资源冷热分层，层次化Cache资源池等挑战
 - Agent执行和交互的全记录，log everything
- ③ 多轮超长轨迹~小时级，天级，周级**
 - 时延矛盾
 - 长上下文管理
- ④ 多agent部署~成百上千并行**
 - 多agent的编排
 - 快速部署可扩展
- ⑤ 环境：可靠，稳定，加速执行**
 - 工具/环境时间尺度上一致性非常强，每次执行结果一样
 - 运行环境稳定，错误不会随时间累积
 - 加速执行，避免工具I/O bound
 - 反馈嵌入到环境和工具里

Agent推理总体趋势：算力变大，内存变高，时延变长，调度弹性

- Agent推理的效率既直接影响RL的吞吐，也影响agent部署实际场景的收益和用户体验，需软硬全栈针对agent负载特点优化加速

算力大：长轨迹x多工具x多agent,推理资源需求剧增

- Anthropic：单agent和多agent系统的token消耗量分别比chatbot多4倍和15倍
- 多轮环境交互；多工具部署

预测：推理算力规模未来可增长1000x；
算力利用率挑战：不同子任务如何编排避免空泡？实时感知负载，调度最合适的计算资源？

内存高：多轮次长轨x个性化，增大KV cache

- 多轮次长轨迹：agent和工具stateful, 任务质量依赖长记忆
- **Agent个性化**意味着记忆开销随交互时长不断增长

预测：内存的需求将不断增长，限制超长任务性能
内存优化挑战：如何利用池化内存？prefix caching命中？高效kv cache优化和压缩？

时延长：工具I/O引入新瓶颈，使时延变长

- 快慢思考和工具调用结合使用，增加端到端时延
- Agent自主化后机-机交互+机-环境交互比人-机交互**频率更高，要求时延更低**

预测：机-机交互低时延和工具调用时延变长冲突
端到端耗时挑战：如何实现高效推理和工具的异步并行执行？多工具之间的并行？LLM推理和工具调用的时延如何均衡？

调度弹性：任务动态编排和推理高可靠

- 长任务的子任务优先级不同
- Agent任务差异大，动态调用多agent/工具/环境，所需算力资源变化大，需弹性扩缩
- 推理系统稳定，可快速恢复

预测：需动态编排多agent/工具和弹性算力资源满足系统SLO
挑战：如何加速CPU？动态CPU:GPU配比？如何GPU-CPU协同融合？

对Agent优化启示：

学会选择生成还是使用工具：随任务需求，学会‘**高效输出**’，选择成本/时延/性价比更合适的方式

并行和投机调用工具算法降低时延：借鉴投机解码算法，预测工具和LLM推理负载，投机使用工具，减少时延

Agentic AI将对算力系统的异构计算、多步异步和动态调度等带来挑战

- Agent的环境探索，长轨迹，多agent，自进化让Agentic RL训练变得复杂；且RL总体算力加速提升，进一步提高计算资源利用率成为刚需
- 环境计算将成为训练和部署阶段的关键一环

环境探索 Scaling

环境数：3个（搜索，浏览，代码）	100个
调用工具数：<10	>100-1000
环境交互次数：<100	>1000

算力大：长轨迹x多工具x多agent,资源需求剧增

Anthropic: 单agent和多agent系统的token消耗量分别比chatbot多4倍和15倍

轨迹 Scaling

序列长度：10-100K tokens	>10M
稳定工作时长~分钟级	天级，周级
多轮次：<10	100-1000

内存高：多轮次长轨x个性化，增大KV cache

KAIST: 使用工具的agent内存开销比CoT多3-5.4倍

Agents Scaling

并行agent部署数量：<10	10K-1000K
多agent间交互+agent-环境交互频率更高，时延更低	QPS*1000

时延长：工具I/O引入新瓶颈，时延变长，放大长尾效应和编排空泡，利用率低

ReACT: 工具时延占总时延>50%

经验 Scaling

Replay buffer样本量: 1B条	>1T条
并行度：Codex best of N=3	>100

- 挑战1-异构计算：生成-交互-反馈-训练的分离式部署；CPU加速和扩展；CPU-GPU协同
- 挑战2-多级存储：长时记忆存储和短期KVCache结合，存储资源冷热分层，层次化Cache资源池
- 挑战3-异步编排：目前最大4步，需支持10+步；流水编排，弹性资源，负载均衡；

将算力底座挑战反馈到模型设计和算法优化，开发系统亲和的agent

硬件亲和agent

模型


1. **高效推理，算力友好**：中等模型规模，高稀疏比MoE，满足inference scaling的模型
2. **长上下文，内存友好**：线性/混合注意力如lightening attention

推理token开销15X

Anthropic：单agent和多agent系统的token消耗量分别比chat多4倍和15倍

挑战：推理算力需求未来可增长1000x；需要更大规模推理集群

累积长context导致时延高



挑战：重复轨迹作为下一轮的上下文，kv缓存开销大

算法


1. **针对异步训练的RL算法减少精度损失**：Meta LlamaRL的AIPO算法，蚂蚁AREAL的异步PPO算法
2. **投机和并行调用工具算法降低时延**：借鉴投机解码算法

RL高吞吐需要推-交互-训分离和异步

- RL精度随数据陈旧度下降
- 目前最多支持4步异步

挑战：多模态生成和工具调用的长时延需要更多异步~10步

工具调用显著增加端到端时延



挑战：工具调用IO时延占比可达50%


框架

1. **训练与生产部署使用相同环境**：OpenAI Codex用真实的环境学习，构建更小、测试的更好的模块
2. **学会选择生成还是使用工具**：随场景选择成本/时延/性价比更合适的方式

agent需要隔离且有状态的环境

- 环境可以独立扩展
- 挑战：环境计算需保持稳定和生成结果的鲁棒性

推理生成bound+工具I/O bound




挑战：推理与工具串行执行->GPU闲置

业界update: RL infra迭代加速, 投入生产, 助力下一代模型训练


6.2 Meta LlamaRL: 分布式异步RL, 405B policy实现10.7倍加速

面向异步训练的针对优化RL算法AIPO - Asynchronous Importance weighted Policy Optimization, 减少off policy对训练精度的影响




6.6阿里ROLL: 支持环境worker和reward worker满足agentic RL的需求

三大特性支持agentic RL: 长任务的多轮agent-环境交互; 可扩展的environment scaling支持高吞吐rollout; 环境执行和actor生成的异步并行, 减少GPU闲置时间




6.4蚂蚁AREAL-训推分离异步RL, 实现2.77倍加速

全异步; 控制数据陈旧度; 动态微批次算法; 可扩展CPU部署支持复杂reward service



6.10Magistral-训推分离部署异步RL

随着RL训练后生成长度变化, 可动态变化的并行批次大小



Agentic AI显著增大算力，内存和时延，将对算力系统的异构计算、多步异步和动态调度等带来挑战


- Agent的环境探索，长轨迹，多agent，自进化让Agentic RL训练变得复杂；且RL总体算力加速提升，进一步提高计算资源利用率成为刚需
- 环境计算将成为训练和部署阶段的关键一环

环境探索 Scaling	环境数：3个（搜索，浏览，代码） 调用工具数：<10 环境交互次数：<5	100个 >100-1000 >100	算力大：长轨迹x多工具x多agent,资源需求剧增 Anthropic: 单agent和多agent系统的token消耗量分别比chatbot多4倍和15倍
轨迹 Scaling	序列长度：10-100K tokens 稳定工作时长~分钟级 多轮次：<10	>10M 天级，周级 100-1000	内存高：多轮次长轨x个性化，增大KV cache KAIST: 使用工具的agent内存开销比CoT多3-5.4倍
Agents Scaling	并行agent部署数量：<10 多agent间交互+agent-环境交互频率更高，时延更低~20QPS	10K-1000K >100QPS	时延长：工具I/O引入新瓶颈，时延变长，放大长尾效应和编排空泡，利用率低 ReACT: 工具时延占总时延> 50%
经验 Scaling	Replay buffer样本量: 1B条 并行度：Codex best of N=3	>1T条 >100	

- 挑战1-异构计算：生成-交互-反馈-训练的分离式部署；CPU加速和扩展；CPU-GPU协同
- 挑战2-多步异步：目前最大4步，需支持10步；流水编排
- 挑战3-动态负载：弹性资源；负载均衡；系统高可靠；

用户ReAct是高质量数据来源，需要记录和保存的用于模型自演进

应用场景	工具调用前Token长度	工具调用后Token长度
算术计算类	~100 tokens	~160–180 tokens
编程执行类	~130 tokens	~250–300 tokens
搜索问答类	~150 tokens	~350–500 tokens
多工具链式调用	~200 tokens	~600–1000 tokens



场景类型	自演进训练方向	输入Token数范围	输出Token数范围	总Token范围	平均ReAct跳数
数学推理	增强符号运算 多步推导能力	120-350	80-200	200-550	3~50
工具调用	提升API参数准确性 错误恢复能力	180-600	40-150	220-750	2~6
知识问答	优化事实核查 多源信息融合	250-1200	150-500	400-1700	4~10
代码生成	提升API兼容性 异常处理完备性	300-900	200-800	500-1700	4~70


多任务：个位数子任务，>10子任务
多环境：少量仿真环境->真实环境
多工具：从当前主要3个工具，到100+digital tools
多轮次：从当前1-3轮，到10s, 100s轮次
多reward：多轮、多层级、多样PRM的稠密奖励

Parameter	Category	Selection	\$ Cost	Power	Latency	Quality
GPU Generation	Hardware Type	Newer	Higher	Higher	Lower/No Change	No Change
CPU vs GPU	Hardware Type	CPU	Lower	Lower	Lower	No Change
Task Parallelism	Resource Amount	More Fan Out	Higher	Higher	Lower	No Change
Execution Paths	Resource Amount	More Paths	Higher	Higher	Higher/No Change	Higher/No Change
Model/Tool	Agent Implementation	More Parameters	Higher	Higher	Higher	Higher/No Change


Agentic RL训练：环境计算成为关键一环，需GPU-CPU协同和沙盒部署，提高端到端吞吐

- Agent的环境探索，长轨迹，多agent，自进化让Agentic RL训练变得复杂；且RL总体算力加速提升，进一步提高计算资源利用率成为刚需
- 环境计算将成为训练和部署阶段的关键一环

Agentic RL: 新增多任务，多环境，多工具，多轮次，多reward的特点



工具调用核心组件：异步，沙盒部署，reward



环境计算

挑战：环境部署需CPU，高并发串行，阻塞GPU，拉低系统效率

挑战：生成-环境交互-reward-训练所需资源差异大，大规模多轮训练下共卡部署无优势

挑战：长轨迹RL训练需要系统稳定和生成结果的鲁棒性

挑战：工具高并发；状态一致性；隔离

GPU-CPU协同加速

- 生成-交互-反馈-训练分离式部署
- CPU加速和扩展
- 异构计算资源

沙盒/容器部署工具

- 连接MCP
- 稳定，弹性，可扩展
- 训练与部署环境相同

吞吐效率

挑战：工具调用耗时长，长尾空泡问题更严重

挑战：多轮交互，pipeline空泡更严重，集群利用率大幅降低

挑战：多轮、多层级、多样奖励拉长reward阶段和其复杂度

多步异步

- 目前最大4步
- 需支持10步

动态负载系统

- 任务流水编排
- 弹性算力资源
- 负载均衡

对agent的优化启示：

针对异步训练的RL算法：减少异步对精度的影响，提高系统异步度从而实现吞吐10x~100x

系统亲和的模型架构：推理算力友好：合适的模型规模/MoE稀疏比；长上下文内存友好：稀疏/线性/混合注意力

Agent推理总体趋势：算力变大，内存变高，时延变长，调度弹性

- Agent推理的效率既直接影响RL的吞吐，也影响agent部署实际场景的收益和用户体验，需软硬全栈针对agent负载特点优化加速

算力大：长轨迹x多工具x多agent,推理资源需求剧增

- Anthropic：单agent和多agent系统的token消耗量分别比chatbot多4倍和15倍
- 多轮环境交互；多工具部署

预测：推理算力规模未来可增长1000x；
算力利用率挑战：不同子任务如何编排避免空泡？实时感知负载，调度最合适的计算资源？

内存高：多轮次长轨x个性化，增大KV cache

- 多轮次长轨迹：agent和工具stateful, 任务质量依赖长记忆
- **Agent个性化**意味着记忆开销随交互时长不断增长

预测：内存的需求将不断增长，限制超长任务性能
内存优化挑战：如何利用池化内存？prefix caching命中？高效kv cache优化和压缩？

时延长：工具I/O引入新瓶颈，使时延变长

- 快慢思考和工具调用结合使用，增加端到端时延
- Agent自主化后机-机交互+机-环境交互比人-机交互**频率更高，要求时延更低**

预测：机-机交互低时延和工具调用时延变长冲突
端到端耗时挑战：如何实现高效推理和工具的异步并行执行？多工具之间的并行？LLM推理和工具调用的时延如何均衡？

调度弹性：任务动态编排和推理高可靠

- 长任务的子任务优先级不同
- Agent任务差异大，动态调用多agent/工具/环境，所需算力资源变化大，需弹性扩缩
- 推理系统稳定，可快速恢复

预测：需动态编排多agent/工具和弹性算力资源满足系统SLO
挑战：如何加速CPU？动态CPU:GPU配比？如何GPU-CPU协同融合？

对Agent优化启示：

学会选择生成还是使用工具：随任务需求，学会‘**高效输出**’，选择成本/时延/性价比更合适的方式

并行和投机调用工具算法降低时延：借鉴投机解码算法，预测工具和LLM推理负载，投机使用工具，减少时延

将算力底座挑战反馈到模型设计和算法优化，开发硬件亲和的agent

模型


1. **高效推理，算力友好**：中等模型规模，高稀疏比MoE，满足inference scaling的模型
2. **长上下文，内存友好**：线性/混合注意力如lightening attention

推理token开销15X

Anthropic：单agent和多agent系统的token消耗量分别比chat多4倍和15倍

挑战：推理算力需求未来可增长1000x；需要更大规模推理集群

累积长context导致时延高



挑战：重复轨迹作为下一轮的上下文，kv缓存开销大

硬件亲和agent

算法


1. **针对异步训练的RL算法减少精度损失**：Meta LlamaRL的AIPO算法，蚂蚁AREAL的异步PPO算法
2. **投机和并行调用工具算法降低时延**：借鉴投机解码算法

RL高吞吐需要推-交互-训分离和异步

- RL精度随数据陈旧度下降
- 目前最多支持4步异步

挑战：多模态生成和工具调用的长时延需要更多异步~10步

工具调用显著增加端到端时延



挑战：工具调用IO时延占比可达50%


框架

1. **训练与生产部署使用相同环境**：OpenAI Codex用真实的环境学习，构建更小、测试的更好的模块
2. **学会选择生成还是使用工具**：随场景选择成本/时延/性价比更合适的方式

agent需要隔离且有状态的环境

- 环境可以独立扩展
- 挑战：环境计算需保持稳定和生成结果的鲁棒性

推理生成bound+工具I/O bound



挑战：推理与工具串行执行->GPU闲置

Agent


针对异步训练的RL

训练与生产部署使用相同环境


模型架构：推理友好的模型规模，稀疏比高效推理，算力友好，稀疏/线性/混合注意力长上下文，内存友好

- Agent的
- 环境计算将成为训练和部署阶段的关键一环

Agentic RL: 新增多环境, 多工具, 多轮次, 多reward的特点



异步, 沙盒部署, reward系统



多agent

挑战：训多agent协同

挑战：RL总体算力加速提升

挑战：生成-环境交互-reward-训练所需资源差异大，大规模多轮训练下共卡部署无优势

多环境

挑战：环境部署需CPU，CPU运行环境和工具慢，阻塞GPU，拉低系统效率

挑战：环境计算资源消耗大，需要大量CPU和内存

挑战：工具调用耗时长，长尾空泡问题更严重

多工具

挑战：工具调用耗时长，工具可与LLM reasoning部分需并行优化

多轮次

挑战：多轮交互，pipeline空泡更严重，集群利用率大幅降低

挑战：长轨迹RL训练需要系统稳定

多reward

挑战：多轮、多层级、多样奖励拉长reward阶段和其复杂度

挑战：从部署的开放环境中交互获得reward用于训练

更多计算资源
(GPU算力, 内存, 带宽, CPU算力)

CPU加速和可扩展

Agent的并行策略和任务编排

RL中生成-交互-反馈-训练多阶段编排和动态调度弹性算力

推-交互-训分离式部署, 异构算力部署

异步训练


分布式系统

环境计算需保持稳定和生成结果的鲁棒性


Agentic RL训练：下一代模型的开放环境，长轨学习和自进化都依赖Agentic RL Infra

- RL训练随agentic tool use变得复杂，rollout生成的时间更长，长尾差异更大；且RL总体算力加速提升，进一步提高计算资源利用率成为刚需

Agentic RL是训练下一代模型的前提，且RL规模会进一步scaling




Agentic RL: 新增多模态，多环境，多工具，多轮次，多agent，多reward的特点




例子：字节Retool；微软agentic tool use；Nemotron-Research-Tool-N1

挑战2：生成-环境交互-reward-训练所需资源差异大，大规模多轮训练下共卡部署无优势




挑战3：引入工具调用后，多轮环境交互使得长尾空泡，pipeline空泡更严重 == 集群利用率大幅降低



挑战4：reward不再是单轮后的单次前向计算；多轮、多层级、多样奖励拉长reward阶段和其复杂度 == 调度难度增加

S0	c	X1	X2	X3	X4	X5	X6	X7	X8	X9	X10	X11	X12	X13
Hidden State	Task Context	Agent output				Env. Output				Agent Output				
Per-token PPO														
Per-turn PPO														
Per-trajectory PPO														

挑战5：探索更多异步步数，当前四野支持4步准异步，异步步数对精度影响仍不明确




吞吐和效率优化思路：从系统，算法和编排提高RL系统端到端吞吐和算力资源利用率


- Agentic RL infra需新增多个特性，业界25H2将加速研发，建议立即准备

推-交互-训分离，异步RL实现多倍加速 25.06蚂蚁AREAL-实现2.77倍加速

全异步；控制数据陈旧度；动态微批次算法；可扩展CPU部署支持复杂reward service



25.04 Intellect-2分布式异步RL



支持异步的RL算法减少精度损失

25.06 Meta LlamaRL: 405B policy实现10.7倍加速

面向异步训练的针对优化RL算法AIPO - Asynchronous Importance weighted Policy Optimization, 减少off policy对训练精度的影响

$$\sum_{t=1}^T \min \left(\frac{\pi(y_t | x, y_{1:t-1})}{\mu(y_t | x, y_{1:t-1})}, \rho \right) \cdot A(x, y_{1:t}) \nabla \log \pi(y_t | x, y_{1:t-1})$$

25.06蚂蚁AREAL


- 数据陈旧度感知训练
- 支持policy版本不一致
- 通过解耦PPO对一个batch训练数据要来自同一个policy的要求，用 π_{behav} 等效不同版本policy

$$J(\theta) = \mathbb{E}_{q \sim \mathcal{D}, a_t \sim \pi_{\text{behav}}} \left[\sum_{t=1}^H \min \left(\frac{\pi_{\theta}}{\pi_{\text{behav}}}, \hat{A}_t, \frac{\pi_{\text{prox}}}{\pi_{\text{behav}}} \text{clip} \left(\frac{\pi_{\theta}}{\pi_{\text{prox}}}, 1 - \epsilon, 1 + \epsilon \right) \hat{A}_t \right) \right]$$
$$= \mathbb{E}_{q \sim \mathcal{D}, a_t \sim \pi_{\text{behav}}} \left[\sum_{t=1}^H \frac{\pi_{\text{prox}}}{\pi_{\text{behav}}} \min \left(u_t^{\text{prox}}(\theta) \hat{A}_t, \text{clip} \left(u_t^{\text{prox}}(\theta), 1 - \epsilon, 1 + \epsilon \right) \hat{A}_t \right) \right]$$


高效流水编排和并行，提高算力利用率

25.05 SkyRL: 多阶段异步并行

Agentic RL训练环境交互时间存在不确定性，多层次多步异步提供更高的灵活性



StreamRL: 动态微批次流水和异步减少空泡



Agent长任务优化：环境计算将成为训练和部署阶段的关键一环

- 做好长轨迹RL和环境计算将支持agent应用到更多的真实业务场景


RL架构需针对长任务的环境计算升级

挑战1：环境资源消耗巨大：如 SWE-Bench每个容器至少需要**>1 CPU 和约 7GB 的存储**。批量大小为 16, 8 个并发rollout可能需要**超过 100 个 CPU 和接近 1TB 的磁盘空间**。

挑战2: CPU运行环境和工具慢, 阻塞GPU, 拉低系统效率

挑战3：环境worker异步并行；rollout scheduler-突破传统批量处理的限制，以单样本粒度管理，并支持优先级样本调度

挑战4：系统稳定，快速恢复：当agent需要持续数小时或数天工作，环境计算需保持稳定和生成结果的鲁棒性




agent需要隔离且有状态的环境

OpenAI Codex: 真实的学习环境:


- 训练与生产部署使用相同环境和相同的容器化基础设施
- 构建更小、测试的更好的模块

SkyRL: 可扩展的环境worker: 利用远程沙盒服务器, 将环境执行与训练过程分离, 使环境可以独立扩展, 从而维持高频率的环境交互, 确保在 rollout 阶段 GPU 资源得到高效利用。




编排提升环境交互效率

包含多个子任务，子任务rollout长短和数量不同：采用不同的编排优化策略



25.05 Minimax Vriune异步reward

RL trainer和reward服务器里不同类型的验证器交互，根据子任务异步返回多样reward



Agent推理总体趋势：算力变大，内存变高，时延变长，调度弹性

	reasoning模型	Agentic模型 ~长任务
算力	Test time scaling-单轮算力	多轮高算力；多模型部署；多工具部署
内存	单轮次cache	多轮次长序列，stateful, 任务质量依赖长记忆
互联	部署模型本身流量	agent通信协议MCP, A2A流量；机-机交互+机-环境交互带来新的流量特征
调度	部署模型的调度	动态调用工具/应用；多agent调度；高时延响应下保证SLO；

需要面向agent设计推理系统，也利用agent感知系统资源，更高效管理，并自我优化

算力大：推理token开销15X

Anthropic博客：单agent和多agent系统的token消耗量分别比chat多4倍和15倍

tokens fast. In our data, agents typically use about 4× more tokens than chat interactions, and multi-agent systems use about 15× more tokens than chats. For economic viability, multi-agent systems

变化：推理需求未来可增长1000x；需要更大规模推理集群


内存高：多轮次的长序列增大KV cache

- Agent原生记忆和stateful工具都有memory开销
- Agent完成长任务的性能依赖长记忆，交互时间长，需要高效管理cache，利用多级存储
- Agent个性化意味着记忆开销不断增长；叠加多agent，memory可能超线性增长

变化：对内存的需求将不断增长；需要池化memory

时延长：工具调用使时延变长

- 快慢思考和工具调用结合使用，增加端到端时延
- 随着agent独立完成任务时长增加，协议MCP, A2A流量可能剧增：机-机交互+机-世界交互比人-机交互频率更高，时延更低




Ayar Labs推断agent高并发低时延的负载需要光I/O支持

变化：机-机交互低时延和工具调用时延变长冲突

调度弹性：任务动态编排和推理高可靠

- 能支持长任务下不同子任务的优先级调度
- 推理系统稳定，可快速恢复：agent长时任务需生成结果鲁棒
- Agent任务差异大，所需算力资源变化大，需弹性扩缩



变化：需动态编排模型/工具和弹性调度算力资源保证系统高效率

